

安徽大学

本科毕业论文

题 目: 模糊最大熵模型及其应用

学生姓名: 覃浩蓝 学号: A01714003

院(系): 数学科学学院 专业: 信息与计算科学

入学时间: 二〇一七年 九月

导师姓名: 吴涛 职称/学位: 教授

导师单位: 数学科学学院

完成时间: 二〇二一年 四月

模糊最大熵模型及其应用

摘 要

本文先介绍了模糊数学中常用的模糊 C 均值 (Fuzzy C-means, FCM) 算法, 在模糊 C 均值算法中, 通过与模糊数学的融合, 给出了相比于 K-means 硬聚类更灵活的聚类结果. 在 FCM 算法的基础上, 我们介绍了一种基于最大熵准则的模型: 模糊最大熵模型. 最后我们在 UCI 的 iris 数据集上应用了 FCM 算法和我们的最大模糊熵模型, 并比较了它们的分类准确率.

关键字: 熵, 最大模糊熵, 模糊聚类

目 录

| | |
|------------------|----|
| 摘 要 | i |
| 1 绪论 | 1 |
| 1.1 研究背景 | 1 |
| 1.2 研究内容 | 1 |
| 1.3 研究意义 | 1 |
| 2 预备知识 | 2 |
| 2.1 模糊集及其表示方法 | 2 |
| 2.1.1 模糊集的定义 | 2 |
| 2.1.2 模糊集的表示方法 | 2 |
| 2.2 模糊集的运算及其性质 | 3 |
| 2.3 模糊 C-均值算法 | 4 |
| 2.4 最大熵原理 | 5 |
| 2.4.1 信息熵 | 5 |
| 2.4.2 最大熵 | 5 |
| 2.5 模糊熵 | 5 |
| 3 模糊最大熵准则的模糊聚类模型 | 7 |
| 3.1 模糊最大熵模型 | 7 |
| 3.2 模糊最大熵模型的求解算法 | 8 |
| 4 模糊最大熵模型分类应用研究 | 9 |
| 4.1 IRIS 数据集 | 9 |
| 4.2 | 10 |
| 5 总结与展望 | 11 |
| 参考文献 | 12 |

1 绪论

1.1 研究背景

进入信息时代后,我们对信息的获取和加工能力在不断进步,我们周围的信息越来越多,五花八门各式各样的信息充斥在我们的生活中,这些信息有的是确定的,但更多的是不确定的、带有模糊性的信息.所谓模糊性是指不确定的,介于是和不是两者之间的性质.例如,对于优等生的判定,有的人觉得 90 就可以了,有的人却觉得需要达到 95 分以上才算优秀,所以我们很难这种非此即彼的性质去衡量一个人是不是优等生.

我们所处的是一个复杂多变、时刻在运动的世界,大到星系运动,小到粒子碰撞,里面蕴含的规律都是复杂多样的.信息本身就包含着确定性和不确定性,无所谓的好坏之分,它取决于我们如何认识信息,了解信息和使用信息.比如,我们在评价某一个菜品时,会用“好吃”、“还行”、“难吃”来形容;描述天气时说“多云”、“晴朗”;说一个人的衣服搭配好看等等.这些问题很难用统一的标准去衡量,但是我们已经习惯在生活中运用模糊性所谓语言描述事物,用模糊的方法认识生活中的事物.虽然信息带着不确定性,但是我们所处的客观世界是确定的,所以我们需要一种方法研究模糊的信息,得到清晰的结论.于是数学诞生了一个新的分支:模糊数学.

1965 年,L.A.Zadeh 在期刊 Information and Control 上发表了论文《Fuzzy Sets》^[1],标志着模糊理论的诞生.随后,1968 年,L.A.Zadeh 又发表了《Probability Measures of Fuzzy Events》^[2],进一步补充模糊理论框架.此后模糊理论开始进入广大学者的视野,不断得到完善和改进,并在控制理论领域得到广泛应用.

1.2 研究内容

最大熵模型是一种分类学习模型,模糊熵是模糊数学里面的概念,本文在模糊理论框架下,将最大熵推广到模型信息情形,在传统的模糊 C 均值聚类(FCM)上进行改进,建立模糊最大熵模型并应用于实际的分类问题中,通过进一步的研究探索模糊最大熵模型在实际问题中的应用.

1.3 研究意义

随着人工智能的大热,机器学习开始迅速应用于我们的生活中,比如商品推荐、语音识别和智能导航等.其中,分类问题是机器学习领域的一个重要问题.生活中许多的分类问题是模糊的,计算机无法直接处理这些模糊信息,而我们的人脑却可以很好地从这些模糊信息中得到精确的结论.随着熵理论和模糊数学的发展,模糊数学和最大熵模型的应用范围也越来越广泛,为了处理分类问题中的不确定性,国内外的许多这方面的学者也进行了许多研究,寻找分类问题模糊性的度量方式,探寻新的实际应用.本文将模糊熵与最大熵原理结合,

2 预备知识

聚类方法不仅是揭示给定数据集的基本结构的主要工具,也是揭示复杂系统的局部输入-输出关系的有效工具.这自然引起了许多学者的兴趣,并由此产生了许多聚类方法,模糊聚类就是其中一种.正如我们所知道的,聚类问题是一个优化问题:一组物体被分割成一个合理的具有某些特征的子群.这往往是在主观选择的测量函数的基础上,将一组物体分成合理数量的子组,使子组内物体之间的距离小于属于不同子组的物体之间的距离.对现有的聚类方法进行改进是一个非常困难的问题,在这之前我们先了解一下模糊 C-均值算法(FCM)方法.

2.1 模糊集及其表示方法

在经典集合理论里面,一个集合就是某一个概念的内涵.对于论域上的一个对象,它要么属于这个集合,要么不属于这个集合,两者只能选一个,不能两者兼之,也不能有模棱两可的情况.而对模糊数学研究的对象来说,我们不能简单地用是或否来描述一个对象是否属于一个集合.由此,我们把集合的特征函数的取值从 $\{0, 1\}$ 这个集合扩充到 $[0, 1]$ 这个区间上的连续取值.越靠近 1,说明该对象属于集合的程度越大,反之,越靠近 0 就越小.这样我们就把经典集合扩充到带有模糊边界的模糊集了,从而我们可以用这样的集合表示模糊概念.

2.1.1 模糊集的定义

定义 2.1.1 (模糊子集^[1]). 设 U 为我们所研究的论域,

$$\mu_{\tilde{A}} : U \longrightarrow [0, 1]$$

称 μ 确定了 U 上的一个模糊子集,记为 \tilde{A} . μ 称为 \tilde{A} 的隶属函数,把 $\mu_{\tilde{A}}(u)(u \in U)$ 的值称为 u 对于模糊子集 \tilde{A} 的隶属度. $\mu_{\tilde{A}}(u)$ 越大,代表 u 隶属于 \tilde{A} 的程度越高.通常,我们也把模糊子集简称为模糊集.

2.1.2 模糊集的表示方法

设有限集 $U = \{u_1, u_2, \dots, u_n\}$, 则有限集可以用如下几种方法表示^[3].

- Zadeh 表示法

$$\tilde{A} = \frac{\tilde{A}(u_1)}{u_1} + \frac{\tilde{A}(u_2)}{u_2} + \dots + \frac{\tilde{A}(u_n)}{u_n}.$$

虽然我们以分式和的方式表示,但是其中的 $\tilde{A}(u_i)/u_i$ 并不表示分数,“+”也不表示和. $\tilde{A}(u_i)/u_i$ 表示的是元素 u_i 与对 \tilde{A} 的隶属度的一一对应关系;“+”表示的是 \tilde{A} 在论域 U 上的整体.

- 序偶表示法

$$\tilde{A} = \{(\tilde{A}(u_1), u_1), (\tilde{A}(u_2), u_2), \dots, (\tilde{A}(u_n), u_n)\}.$$

序偶表示法是从例举法演变而来, 由元素的隶属度和对应的元素组成的有序对列出.

- 向量表示法

$$\tilde{A} = (\tilde{A}(u_1), \tilde{A}(u_2), \dots, \tilde{A}(u_n)).$$

向量表示法是用 n 维数组来实现的, 在论域中的元素按一定的顺序排列时, 按此顺序记录元素的隶属度. 此时也称 \tilde{A} 为模糊向量.

2.2 模糊集的运算及其性质

我们先给出模糊幂集的定义:

定义 2.2.1. 论域 U 上的模糊子集的全体称为模糊幂集, 记为 $\mathcal{F}(U)$, 即

$$\mathcal{F}(U) = \{\tilde{A} \mid \tilde{A}(u) : U \rightarrow [0, 1]\}$$

模糊集的包含与相等:

定义 2.2.2. 设 $\tilde{A}, \tilde{B} \in \mathcal{F}(U)$, 如果对 $\forall u \in U$ 都成立 $\tilde{B}(u) \geq \tilde{A}(u)$, 则称 \tilde{B} 包含 $\tilde{A}(u)$, 记作 $\tilde{B}(u) \supseteq \tilde{A}(u)$.

定义 2.2.3. 设 $\tilde{A}, \tilde{B} \in \mathcal{F}(U)$, 如果对 $\forall u \in U$ 都成立 $\tilde{B}(u) = \tilde{A}(u)$, 则称 \tilde{B} 等于 $\tilde{A}(u)$, 记作 $\tilde{B}(u) = \tilde{A}(u)$.

我们规定 $a \vee b = \text{MAX}(a, b)$, $a \wedge b = \text{MIN}(a, b)$, 所以我们可以这样描述模糊集的并、交、余:

定义 2.2.4. 如果对于任意一个 $u \in U$, 有 $\tilde{C}(u) = \tilde{A}(u) \vee \tilde{B}(u)$, 则称 \tilde{C} 为 \tilde{A} 与 $\tilde{B}(u)$ 的并, 记为 $\tilde{C} = \tilde{A} \cup \tilde{B}$. 如果对于任意一个 $u \in U$, 有 $\tilde{C}(u) = \tilde{A}(u) \wedge \tilde{B}(u)$, 则称 \tilde{C} 为 \tilde{A} 与 $\tilde{B}(u)$ 的交, 记为 $\tilde{C} = \tilde{A} \cap \tilde{B}$.

它们的隶属度函数定义为:

$$(\tilde{A} \cup \tilde{B})(u) \stackrel{\text{def}}{=} \tilde{A}(u) \vee \tilde{B}(u), \forall u \in U$$

$$(\tilde{A} \cap \tilde{B})(u) \stackrel{\text{def}}{=} \tilde{A}(u) \wedge \tilde{B}(u), \forall u \in U$$

定义 2.2.5. 如果对于 $\forall u \in U$, 有 $\tilde{B}(u) = 1 - \tilde{A}(u)$, 则称 \tilde{B} 为 \tilde{A} 的余, 记为 $\tilde{B} = \tilde{A}^c$.

2.3 模糊 C-均值算法

C-均值聚类是我们聚类经常用的方法之一, 通过迭代计算使得目标函数达到局部最小值的时候, 就是我们的最优分类. 在模糊 C-均值聚类中, 我们定义目标函数为:

$$J(A, V) = \sum_{i=1}^c \sum_{j=1}^n (a_{ij})^r d_{ij}^2 \quad (2-1)$$

$U = \{u_1, u_2, \dots, u_n\}$, $u_j = (x_{j1}, x_{j2}, \dots, x_{jm}) \in R^m$ 为给定的 n 个样本的 m 维数据集, $A = (a_{ij})$ 是隶属度矩阵, r 是模糊数, $d_{ik} = \|u_k - v_i\|$ 是第 k 个样本到第 i 个聚类中心的距离.

当 v_i 不变时问题等价于

$$\min L(A, \lambda) = \sum_{i=1}^c \sum_{j=1}^n (a_{ij})^r d_{ik} \quad (2-2)$$

$$s.t. \sum_{i=1}^c a_{ik} = 1, \forall k \quad (2-3)$$

这是最优化问题, 我们引入拉格朗日乘子 λ , 于是变为

$$L(A, \lambda) = \sum_{i=1}^c \sum_{j=1}^n (a_{ij})^r \|u_j - v_i\|^2 - \sum_{j=1}^n \lambda_j \left(\sum_{i=1}^c a_{ij} - 1 \right) \quad (2-4)$$

对式2-4求导, 局部最小值时必要条件为

$$\frac{\partial L(A, \lambda)}{\partial a_{ij}} = \left[r (a_{ij})^{r-1} \|u_j - v_i\|^2 - \lambda_j \right] = 0 \quad (2-5)$$

$$\frac{\partial L(A, \lambda)}{\partial \lambda_j} = \sum_{i=1}^c a_{ij} - 1 = 0 \quad (2-6)$$

由式2-5可得:

$$a_{ij} = \left(\frac{\lambda_j}{r \|u_j - v_i\|^2} \right)^{\frac{1}{r-1}} \quad (2-7)$$

将式2-7带入式2-6解得:

$$\left(\frac{\lambda_j}{r} \right)^{\frac{1}{r-1}} = \left[\sum_{i=1}^c \left(\frac{1}{r \|u_j - v_i\|^2} \right)^{\frac{1}{r-1}} \right]^{-1} \quad (2-8)$$

最后将式2-8代入式2-7得到隶属度的更新公式为:

$$a_{ij} = \left[\sum_{j=1}^c \left(\frac{\|u_j - v_i\|}{\|u_j - v_j\|} \right)^{\frac{2}{r-1}} \right]^{-1} \quad 1 \leq i \leq c, \quad 1 \leq j \leq n \quad (2-9)$$

假设 a_{ij} 不变, 原问题就变成了无约束最优化问题, 必要条件为:

$$\frac{\partial J(A, V)}{\partial v_i} = - \sum_{j=1}^n 2 (a_{ij})^r (u_j - v_i) = 0 \quad (2-10)$$

解之得:

$$v_i = \frac{\sum_{j=1}^n (a_{ij})^r u_j}{\sum_{j=1}^n (a_{ij})^r}, \quad 1 \leq i \leq c \quad (2-11)$$

需要注意的是, 算法中要求 $v_i \neq u_j$, 因此, 在遇到只有一个样本的类别时, 需要将此类别排除, 在聚类结束时再加上.

2.4 最大熵原理

熵原本是物理学中的概念, 是由热力学第二定律引出的一个物质系统的状态参量, 是反映系统的混乱程度, 度量信息有效性的一个重要工具. 自从熵的概念被提出来之后, 很快引起了其他领域研究者的注意, 熵理论得以迅速传播, 渗透进各个领域.

2.4.1 信息熵

1948 年, 香农^[4] 提出了信息熵的概念, 解决了信息的量化度量问题.

(1) 离散模糊变量的信息熵

设某个离散型的随机变量 X , X 的分布率是 $\{p_i\}$, 且 $p_i = P\{X = x_i\}$, $0 \leq p_i \leq 1$, $\sum_{i=1}^n p_i = 1$, ($i = 1, 2, \dots, n$) 则用信息熵来度量事件 X 的确定程度为:

$$H(X) = - \sum_{i=1}^n p_i \ln p_i \quad (2-12)$$

(2) 连续连续模糊变量的信息熵

假设某个连续型随机变量 X , 其概率密度函数是 $p(x)$, 则该连续随机变量 X 的信息熵为:

$$H(X) = - \int p(x) \ln p(x) dx \quad (2-13)$$

2.4.2 最大熵

1957 年, E.T.Jaynes 提出了最大熵原理, 通过把随机变量与信息熵联系起来, 然后最大化信息熵. 最大熵原理并不是某一固定的数学公式, 而是一种选择随机变量的准则. 最大熵的主要思想是, 在我们只掌握未知变量的部分知识的时候, 未知变量的分布可能有很多种, 此时我们应该选符合这些知识的情况下, 使得信息熵取得最大值的概率分布.

2.5 模糊熵

在自然界以及我们的日常生活中, 经常存在着带着模糊性质的不确定现象, 我们把它定义成模糊变量. 自从模糊理论提出以后, 很多学者就在如何度量模糊变量的模糊程度

这一方面进行了许多研究, 比如 Li, Pingke 和 Liu, Baoding^[5]、Aldo de Luca 和 Settimo Termini^[6] 等.

定义 2.5.1 (模糊熵). 对于离散变量的模糊

$$H(\tilde{A}) = - \sum_{i=1}^n \tilde{A}(u_i) \ln \tilde{A}(u_i) \quad (2-14)$$

对于连续的模糊变量

$$H(\tilde{A}) = - \int_{-\infty}^{\infty} \tilde{A}(u) \ln \tilde{A}(u) du \quad (2-15)$$

3 模糊最大熵准则的模糊聚类

3.1 模糊最大熵模型

前面我们介绍了模糊聚类的一种常用方法: 模糊 C-均值聚类, 介绍了模糊熵和最大熵原理。现在, 我们就可以将最大熵原理推广到模糊熵的情形, 在模糊 C-均值聚类中加入模糊最大熵进行约束。设 a_{ij} 为第 j 个元素对于第 i 类的隶属度, 则我们模糊最大熵模型 (Fuzzy Maximum Entropy.FME) 的目标函数可以表示成

$$\max \left\{ - \sum_{j=1}^n \sum_{i=1}^c a_{ij} \ln a_{ij} \right\} \quad (3-1)$$

我们首先得定义我们的损失函数, 在这里, 我们选取

$$L = \sum_{i=1}^c \sum_{j=1}^n a_{ij} d_{ij}^2$$

作为我们的损失函数。于是我们可以将问题归结为最优化问题, 用拉格朗日乘法:

$$L(A, \beta, \lambda) = \sum_{i=1}^c \sum_{j=1}^n a_{ij} d_{ij}^2 + \beta \sum_{i=1}^c \sum_{j=1}^n a_{ij} \ln a_{ij} + \sum_{j=1}^n \lambda_j \left(\sum_{i=1}^c a_{ij} - 1 \right) \quad (3-2)$$

其中 β 是差异因子, 由数据集的分布情况来决定, λ_j 是 $\sum_{i=1}^c a_{ij}$ 的拉格朗日乘子。

$$\frac{\partial L(A, \beta, \lambda)}{\partial a_{ij}} = d_{ij}^2 + \beta(\ln a_{ij} + 1) + \lambda_j = 0 \quad (3-3)$$

$$\frac{\partial L(A, \beta, \lambda)}{\partial \lambda_j} = \sum_{i=1}^c a_{ij} - 1 = 0 \quad (3-4)$$

最后解得

$$a_{ij} = \frac{\exp(-\frac{d_{ij}^2}{\beta})}{\sum_{i=1}^c \exp(-\frac{d_{ij}^2}{\beta})} \quad (3-5)$$

$$v_i = \frac{\sum_{j=1}^n a_{ij} x_j}{\sum_{j=1}^n a_{ij}} \quad (3-6)$$

3.2 模糊最大熵模型的求解算法

在描述我们的算法之前, 我们首先来定义一些模型的输入输出:

n 个样本的 m 维数据集 $U : U = \{u_1, u_2, \dots, u_n\}, u_i = \{x_1, x_2, \dots, x_m\} \forall i$

聚类数 $c : 2 \leq c \leq n$

隶属度矩阵 $A : n \times m$ 的矩阵

聚类中心 $V : c \times m$ 的矩阵

模糊最大熵模型的聚类算法步骤如下:

输入: 原始数据 U 和聚类数 c

输出: 隶属度矩阵 A 和聚类中心 V

- 1) 首先随机初始化隶属度矩阵并归一化;
- 2) 根据式3-6计算聚类中心;
- 3) 计算每一个元素到聚类中心的距离;
- 4) 根据式3-5更新隶属度矩阵;
- 5) 如果到达指定精度或迭代次数, 结束计算过程, 否则重复 2 ~ 4 步;
- 6) 输出隶属度矩阵 A 和聚类中心 V .

4 模糊最大熵模型分类应用研究

4.1 IRIS 数据集

此数据是来自 UCI 的鸢尾花 (iris) 数据集。这是一个经典的分类数据集, 由 Iris Setosa(山鸢尾)、Iris Versicolour(杂色鸢尾) 和 Iris Virginica(维吉尼亚鸢尾) 三种不同类别的鸢尾花组成, 每个样本由四个属性组成, 分别是 Petal.Length(花瓣长度)、Petal.Width(花瓣宽度)、Sepal.Length(花萼长度) 和 Sepal.Width(花萼宽度)。按两两属性绘制原始数据如下:

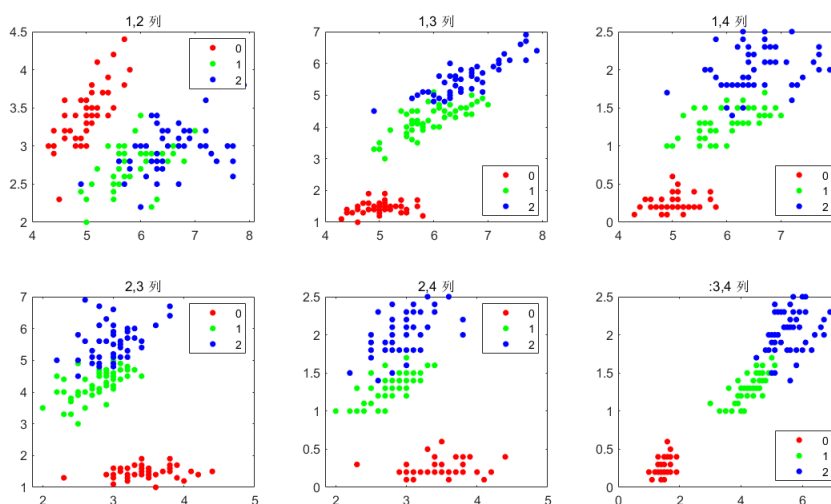


图 4.1 原始数据散点图

按 4.1 的算法对 iris 数据集进行聚类, 结果如下:

表 4.1 聚类中心

| | sepal length | sepal width | petal length | petal width |
|-------|--------------|-------------|--------------|-------------|
| v_1 | 5.0136 | 3.3903 | 1.5369 | 0.2781 |
| v_2 | 6.4737 | 2.9437 | 5.1910 | 1.8012 |
| v_3 | 6.0922 | 2.8186 | 4.6775 | 1.5731 |




图 4.2 隶属度矩阵的值

与 FCM 算法分类结果比较 从数据的比较中, 可以看到, 对于第一类, 三个算法都做

表 4.2 准确率比较

| 算法/各类准确率 | Setosa(山鸢尾) | Versicolour(杂色鸢尾) | Virginica(维吉尼亚鸢尾) | 总样本 |
|----------|-------------|-------------------|-------------------|-------|
| K-means | 100% | 96% | 72% | 89.4% |
| FCM | 100% | 76% | 94% | 90% |
| MFE | 100% | 86% | 98% | 94.7% |

到了很好的识别, 但是对于后两类非线性相关的类别, 模糊最大熵模型比其他两个模型有着更好的表现.

4.2 红酒数据集

5 总结与展望

独立的系统演化是一个熵增的过程, 在没有外力的作用下, 熵是一直增加的, 即符合我们的最大熵原理. 而自然界也是一个巨大的系统, 时时刻刻产生信息, 有精确的, 但许多都是模糊的. 为了在已有的知识下, 使我们的结果更加准确, 我们趋向于使得信息的熵最大, 于是我们在 FCM 的基础上融入了最大熵模型, 形成了模糊最大熵模型. 最后我们将模糊最大熵模型应用于 iris 数据集的分类, 取得了相对于 FCM 算法更好的聚类效果.

现如今, 适逢新一代人工智能的浪潮, 各种智能算法、机器学习研究论文层出不穷, 而模糊聚类在图像分割、目标识别、故障诊断等方面也有广泛的应用, 相信在不久的将来, 关于模糊最大熵模型的应用于机器学习的结合会越来越多, 推动模糊分类算法变得越来越好.

参考文献

- [1] ZADEH L A. Fuzzy sets[J]. Information and Control, 1965, 8(3): 338-353.
- [2] ZADEH L A. Probability measures of fuzzy events[J]. Journal of mathematical analysis and applications, 1968, 23(2): 421-427.
- [3] 李安贵, 张志宏. 模糊数学及其应用 [M]. (第 2 版). 北京: 冶金工业出版社, 2005.
- [4] SHANNON C E. A mathematical theory of communication[J]. The Bell System Technical Journal, 1948, 27(4): 379-423.
- [5] LI P, LIU B. Entropy of credibility distributions for fuzzy variables[J]. IEEE Transactions on Fuzzy Systems, 2008, 16(1): 123-129.
- [6] DE LUCA A, TERMINI S. A definition of a nonprobabilistic entropy in the setting of fuzzy sets theory[J]. Information and Control, 1972, 20(4): 301-312.
- [7] 谭扬波, 陈光 (禹). 一种基于最大模糊熵的高斯聚类算法 [J]. 电子科技大学学报, 2000 (3): 269-272.
- [8] QIAN P, SUN S, JIANG Y, et al. Cross-domain, soft-partition clustering with diversity measure and knowledge reference[J]. Pattern Recognition, 2016, 50.
- [9] FU H J, WU X H, MAO H P, et al. Fuzzy entropy clustering using possibilistic approach[J]. Procedia Engineering, 2011, 15: 1993-1997.
- [10] LI R P, MUKAIDONO M. A maximum-entropy approach to fuzzy clustering[C]// Proceedings of 1995 IEEE International Conference on Fuzzy Systems. [S.l.: s.n.], 1995.

致谢

谢谢！